



Bible-API: сравнение скорости Qwen и Gemma

Qwen3-30B-A3B FP8 Gemma 4 31B FP8 p50 p95


Наводящий вопрос




Rewrite для поиска Писания



Rerank отрывков



Общая пропускная способность



Qwen: RTX 4090 48 ГБ (по данным владельца); Gemma: L40S 48 ГБ. Разные стенды и сетевые пути; прогретый кэш; повторяющийся короткий набор; n=20 на стадию и уровень. p95 — исследовательская оценка.